

ΤΕΧΝΙΚΕΣ ΕΞΟΡΥΞΗΣ ΔΕΔΟΜΕΝΩΝ
ΑΣΚΗΣΗ 2

ΣΤΑΜΑΤΟΠΟΥΛΟΣ ΒΑΣΙΛΕΙΟΣ
(1115201400188)

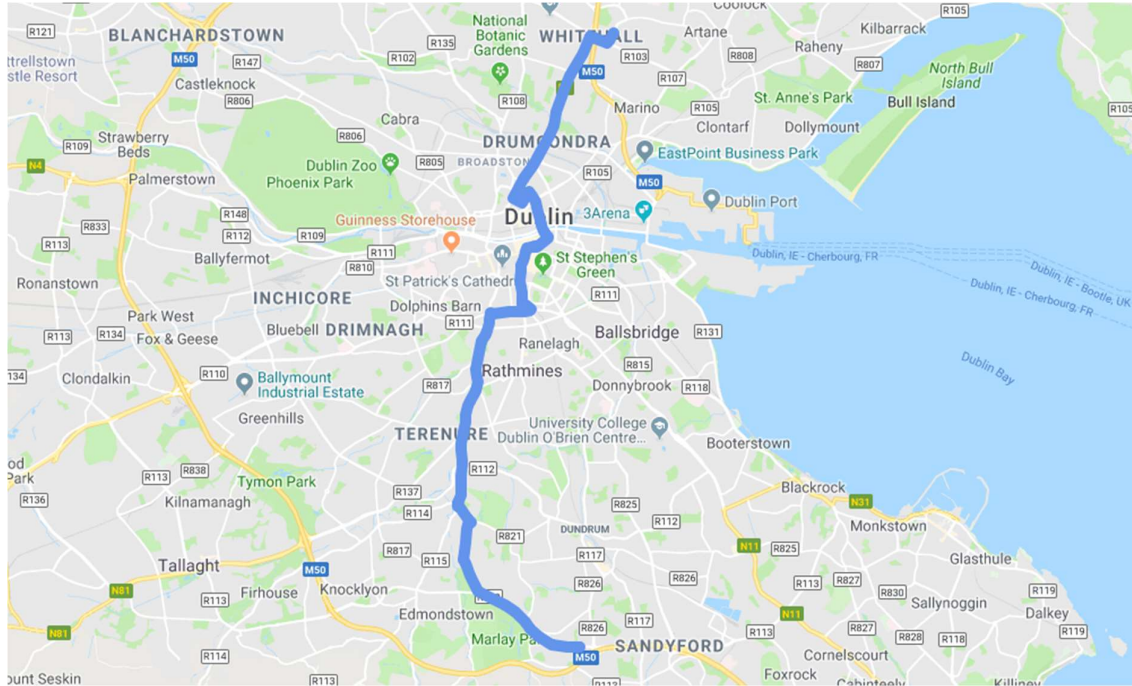
—

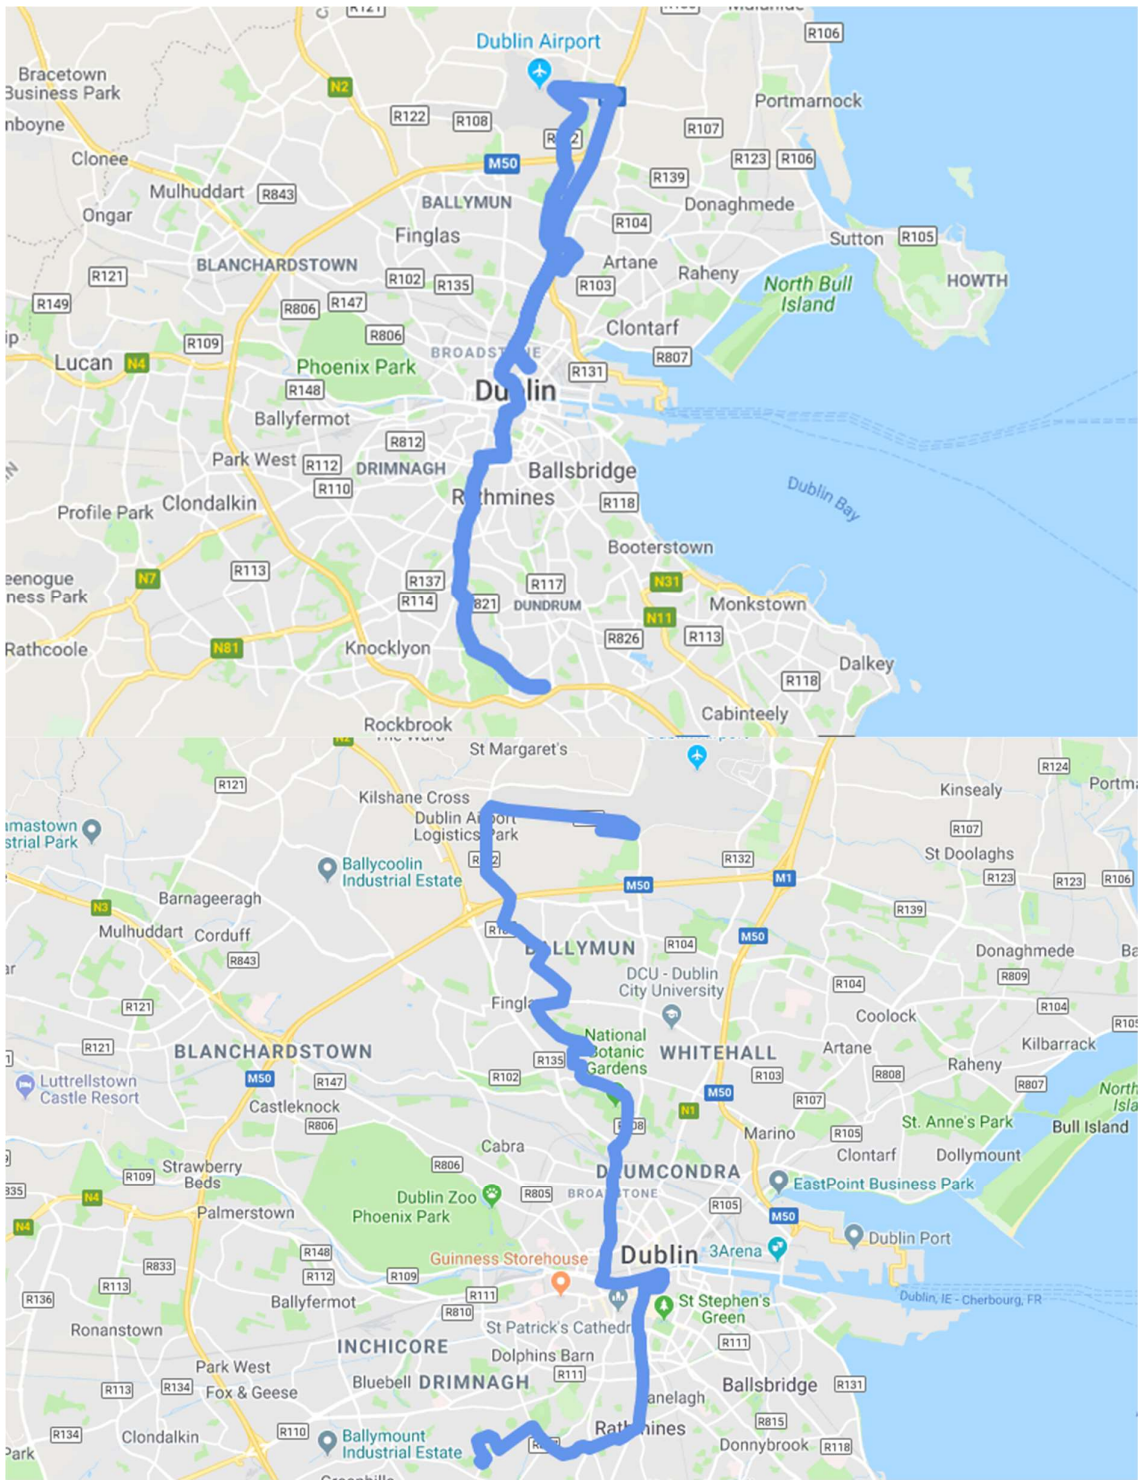
ΚΟΥΚΑΚΗΣ ΚΩΝΣΤΑΝΤΙΝΟΣ
(1115201400289)

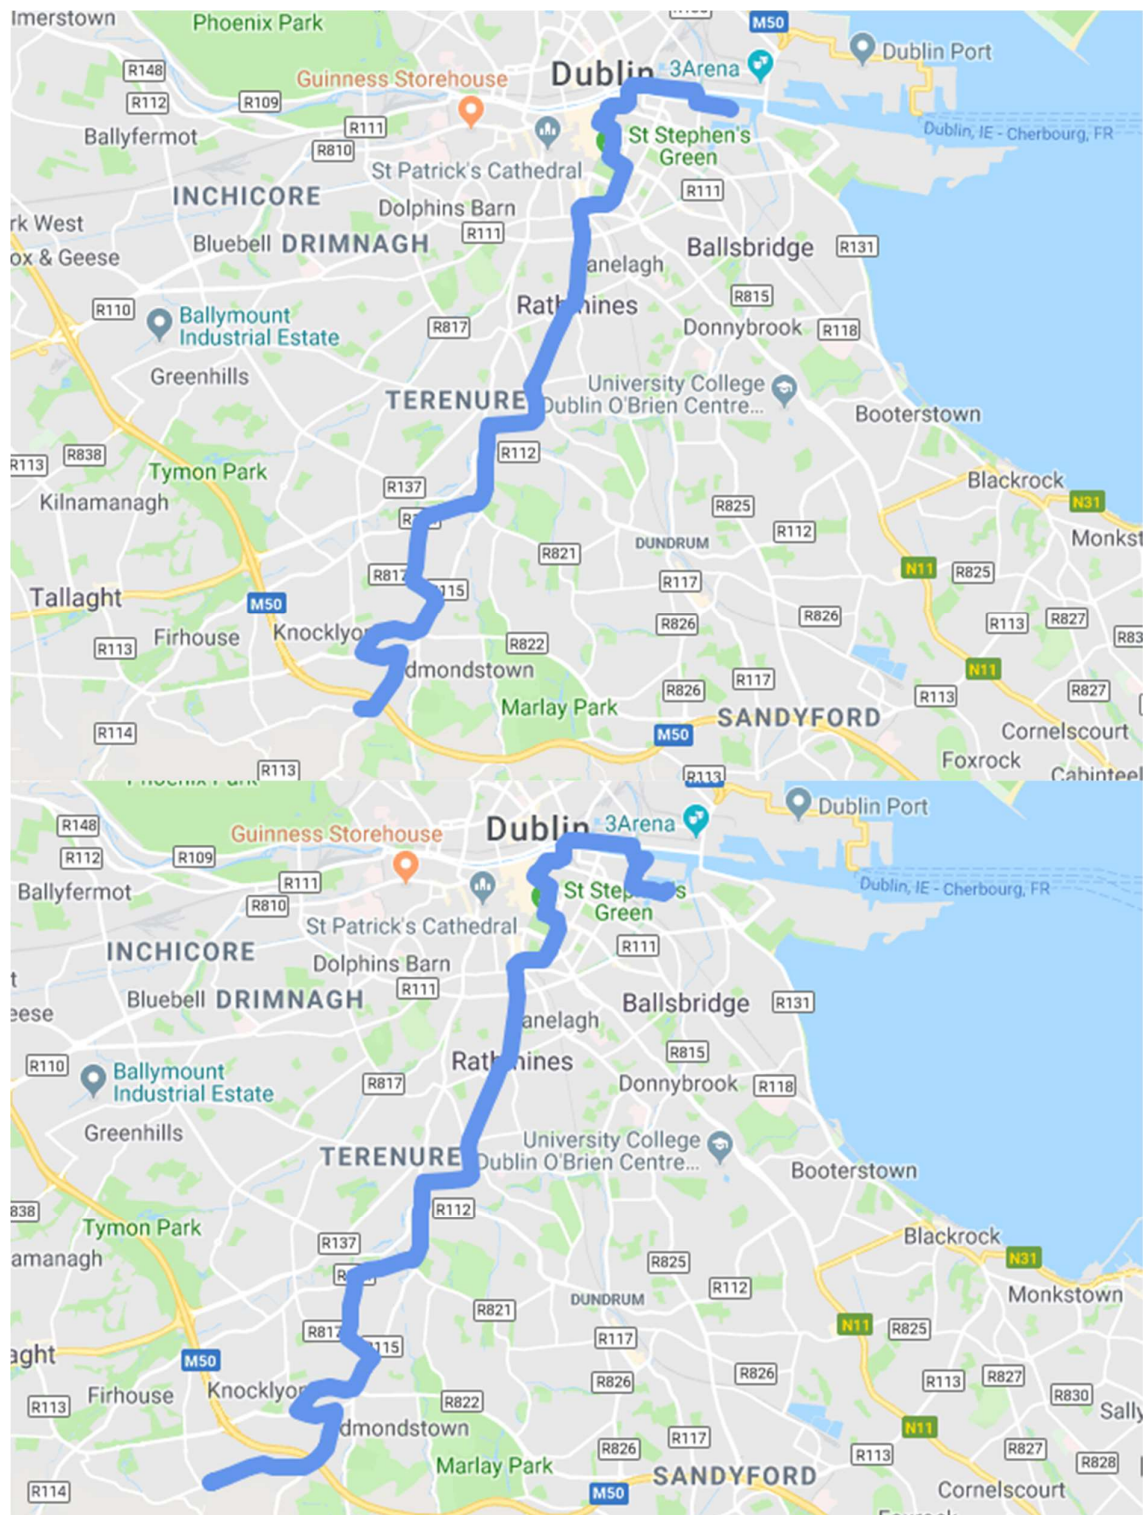
Ερώτημα 1

Το ερώτημα αυτό απαντήθηκε στο αρχείο mapping.py με τα αποτελέσματα του να βρίσκονται στο φάκελο maps. Πήραμε 5 τυχαία ids από το dataset και βρήκαμε την πρώτη εμφάνιση του καθενός στο σύνολο και χαρτογραφήσαμε την καθεμιά από αυτές. Έχουμε 5 δυάδες λιστών lats και lons, και αναλόγως τις γεμίζουμε με τα δεδομένα των συντεταγμένων.

Τέλος, χαρτογραφούμε τις διαδρομές με τη χρήση του **gmpplot** και παίρνουμε τα παρακάτω αποτελέσματα.








Ερώτημα 2

A.


Για το ερώτημα αυτό ο κώδικας βρίσκεται στο αρχείο `dtw_nn.py`. Εκεί, υπάρχει μια συνάρτηση η οποία υπολογίζει την απόσταση haversine μεταξύ δύο σημείων συντεταγμένων. Για κάθε trajectory στο σύνολο ελέγχου, παίρνουμε τις συντεταγμένες και τις αποθηκεύουμε σε δύο λίστες. Έπειτα, δημιουργούμε ένα `.html` αρχείο το οποίο αναπαριστά τη διαδρομή και θα το χρησιμοποιήσουμε αργότερα στα αποτελέσματα. Υπολογίζουμε την `dtw` της διαδρομής με κάθε διαδρομή στο σύνολο εκπαίδευσης, και για αυτή τη διαδικασία χρησιμοποιούμε τον αλγόριθμο της βιβλιοθήκης `dtw`.

Στη συνέχεια, τοποθετούμε όλες τις αποστάσεις σε μια λίστα από tuples `{διάσταση, index}`, ταξινομούμε την λίστα βάση της απόστασης και βρίσκουμε τις 5 μικρότερες. Τέλος, αφού χαρτογραφήσουμε τις γειτονικές αποστάσεις, με τη βοήθεια του `iframe`, φτιάχνουμε έναν πίνακα `html` για να δώσουμε τα αποτελέσματα, τα οποία δίνονται στη συνέχεια.


Χρόνος Εκτέλεσης: 2428.12000012



Test Trip 1
Dt= 1223.76438594sec




Neighbor 1
JP_ID: 01501001
DTW: 0.0



Neighbor 2
JP_ID: 01501001
DTW: 0.013874606415368754




Neighbor 3
JP_ID: 01501001
DTW: 0.01522404812947076




Neighbor 4
JP_ID: 01501001
DTW: 0.015736379836091052



Neighbor 5
JP_ID: 01501001
DTW: 0.016013091332028724




Test Trip 2
Dt= 623.550071955sec




Neighbor 1
JP_ID: 01200001
DTW: 0.0




Neighbor 2
JP_ID: 01200001
DTW: 0.020685469224294074




Neighbor 3
JP_ID: 01200001
DTW: 0.022780762378723198




Neighbor 4
JP_ID: 01200001
DTW: 0.02432501949003578




Neighbor 5
JP_ID: 01200001
DTW: 0.02438856487725342




Test Trip 3
Dt= 1173.08323908sec



Neighbor 1
JP_ID: 00791001
DTW: 0.0




Neighbor 2
JP_ID: 00791001
DTW: 0.015336994044971993



Neighbor 3
JP_ID: 00791001
DTW: 0.016580769101374924




Neighbor 4
JP_ID: 00791001
DTW: 0.01710115456587192




Neighbor 5
JP_ID: 00791001
DTW: 0.017658909723781403



Test Trip 4
Dt= 755.005935907sec



Neighbor 1
JP_ID: 00010002
DTW: 0.0




Neighbor 2
JP_ID: 00010002
DTW: 0.014882175877381278




Neighbor 3
JP_ID: 00010002
DTW: 0.017247889261746016




Neighbor 4
JP_ID: 00010002
DTW: 0.019696952751058337




Neighbor 5
JP_ID: 00010002
DTW: 0.019894708089114727



Test Trip 5
Dt= 760.965547085sec




Neighbor 1
JP_ID: 01300001
DTW: 0.0




Neighbor 2
JP_ID: 01300001
DTW: 0.024293949698498574



Neighbor 3
JP_ID: 01300001
DTW: 0.024818117863589624



Neighbor 4
JP_ID: 01300001
DTW: 0.02561600605820375



Neighbor 5
JP_ID: 01300001
DTW: 0.025947464263656815


B.

Για το ερώτημα αυτό ο κώδικας βρίσκεται στο αρχείο lcss.py. Η διαδικασία μοιάζει αρκετά με αυτή του προηγούμενου ερωτήματος μόνο που εδώ αντί για μικρότερες αποστάσεις, ψάχνουμε τα περισσότερα κοινά σημεία. Τα σημεία αυτά τα βρίσκουμε με τον αλγόριθμο lcs (longest common subsequence), ο οποίος επιστρέφει δύο πράγματα. Τον αριθμό των ταιριαστών σημείων και το μεγαλύτερο κοινό μονοπάτι. Δύο σημεία ταιριάζουν όταν απέχουν λιγότερο από 200m. Για το κοινό μονοπάτι χρησιμοποιούμε την συνάρτηση common_path οι οποία πέρνει των πίνακα που δημιουργεί η lcs και το test path και ελέγχει τα ταιριαστά διαγώνια σημεία και αναλόγως μειώνει το αντίστοιχο index (l,j). Στην ουσία κάνει traverse των πίνακα όπως θα τον έκανε και η lcs. Τέλος, αφού έχουμε το κοινό μονοπάτι και τα κοινά σημεία τα τοποθετούμε σε μια λίστα και δημιουργούμε ένα tuple του τύπου: matching = [[#no of points, [common_path]], index].


Σε αυτή τη δομή βρίσκονται όλα τα στοιχεία που χρειαζόμαστε για να καταγράψουμε τα αποτελέσματα μας.

Τα αποτελέσματα δίνονται παρακάτω:







Test Trip 2
Dt= 747.889531851sec




Neighbor 1
JP_ID: 040D1002
Matching Points: 82




Neighbor 2
JP_ID: 040D1002
Matching Points: 78




Neighbor 3
JP_ID: 040D1002
Matching Points: 75




Neighbor 4
JP_ID: 040D1002
Matching Points: 74




Neighbor 5
JP_ID: 040D1002
Matching Points: 73




Test Trip 3
Dt= 362.457656145sec




Neighbor 1
JP_ID: 01451001
Matching Points: 40



Neighbor 2
JP_ID: 079A0001
Matching Points: 40




Neighbor 3
JP_ID: 066X0004
Matching Points: 40




Neighbor 4
JP_ID: 00790001
Matching Points: 40




Neighbor 5
JP_ID: 01451008
Matching Points: 40




Test Trip 4
Dt= 516.552026033sec




Neighbor 1
JP_ID: 00790001
Matching Points: 59




Neighbor 2
JP_ID: 00790001
Matching Points: 59



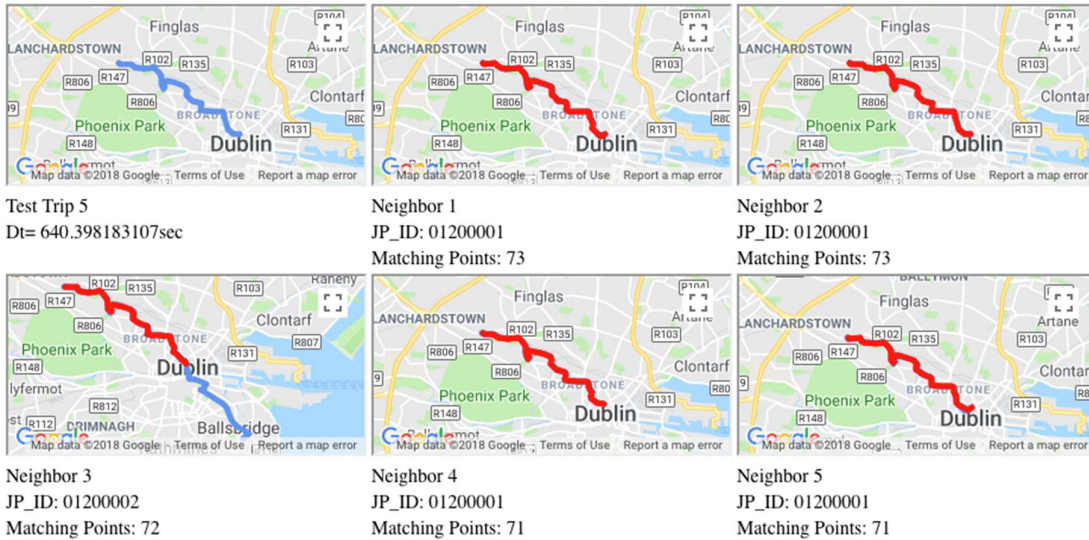
Neighbor 3
JP_ID: 00790001
Matching Points: 59



Neighbor 4
JP_ID: 00790001
Matching Points: 59



Neighbor 5
JP_ID: 00790001
Matching Points: 59



ΧΡΟΝΟΣ ΕΚΤΕΛΕΣΗΣ: 1344.80699992 sec

Ερώτημα 3

Στο ερώτημα αυτό χρησιμοποιήσαμε τον αλγόριθμο που φτιάξαμε στην προηγούμενη εργασία για να ταξινομήσουμε τις διαδρομές του test_set.

Τα αποτελέσματα της απλής ταξινόμησης ήταν τα εξής:

- 1 040D1002
- 2 01201001
- 3 00371001
- 4 00790001
- 5 01200001

Για την διασταυρούμενη επικύρωση χρησιμοποιήσαμε τον ίδιο αλγόριθμο με το StratifiedKfold(), αλλά η διαδικασία δεν τερμάτιζε ποτέ. Σπάσαμε το σύνολο και χρησιμοποιήσαμε μονάχα το 10% του συνόλου για το οποίο πήραμε accuracy = 0.90920